

Weekly Sprint Report

Deployment Model MultiDeepC ke Raspberry Pi 5 + Hailo-8L

Sprint: Deployment Bring-up | Tanggal: June 29, 2026 | Owner: Riyadh

Repo: <https://github.com/riyadh-gif/dini-deploy> (private)

Sprint Goal

Mengemas model MultiDeepC (klasifikasi kondisi lahan per grid) menjadi container Docker yang dapat dijalankan di perangkat edge Raspberry Pi 5 dengan akselerator Hailo-8L, lalu memverifikasi seluruh jalur inferensi di hardware sebenarnya sebelum diserahkan ke tim hardware.

Ringkasan Eksekutif

Container Docker yang memakai NPU Hailo-8L sudah dibangun dan terbukti berjalan di Raspberry Pi 5. Seluruh pipeline dari checkpoint PyTorch sampai inferensi di NPU sudah diverifikasi di hardware. Latensi inferensi sekitar 0.3 ms per grid. Dua artefak preprocessing (scaler dan CNN) masih menjadi dependensi terbuka untuk akurasi produksi.

Pekerjaan Selesai Sprint Ini

- **Done** Rekonstruksi arsitektur MultiDeepC dari checkpoint, strict load 115 tensor.
- **Done** Verifikasi clustering head DEC (Student-t, alpha 1.0) cocok output pelatihan (selisih 5e-7).
- **Done** Ekspor jalur encoder ke ONNX opset 11, seluruh operator didukung Hailo.
- **Done** Kompilasi HEF via Hailo Dataflow Compiler 3.33.1, target hailo8l.
- **Done** Build dan jalankan container Docker (backend CPU dan backend Hailo NPU) di Pi.
- **Done** Verifikasi di hardware: HEF load pada HailoRT 4.23.0, inferensi NPU end-to-end.
- **Done** Repo, README, dokumen serah terima, dan skrip PoC demo siap untuk tim hardware.

Metrik Sprint

Metrik	Nilai	Catatan
Latensi inferensi (NPU encode)	0.27 ms median	per grid, sinkron
Latensi full path (NPU + DEC head)	0.34 ms mean	termasuk clustering head CPU
Throughput streaming (NPU)	15.480 inferensi/detik	mode pipelined
Latensi via container HTTP	5 sampai 6 ms	termasuk FastAPI dan jaringan
Ukuran HEF	762 KB	model terkompilasi
Image container Hailo	403 MB	arm64, debian trixie
Operator tidak didukung Hailo	0	tidak perlu partisi graf

Demo

1. `sudo docker ps` menampilkan container `mdc-hailo` berjalan di Pi.
2. `GET /health` mengembalikan `"backend":"hailo"` (inferensi di NPU).
3. `POST /predict` dengan data 1 grid mengembalikan label kondisi lahan.
4. Skrip `poc_demo.py` menampilkan tabel beberapa grid menuju label beserta latensi.

Blocker dan Risiko

- **In Progress** Scaler pelatihan hilang. Saat ini memakai placeholder identitas, sehingga nilai prediksi belum membedakan antar kelas. Perlu file scaler atau matrix input pelatihan.

- **In Progress CNN feature extractor hilang.** Branch citra (64 fitur) diisi nol. Perlu model CNN beserta kode arsitekturnya untuk pipeline citra end-to-end.
- **Akurasi belum final.** Kompilasi memakai calibration sintetis. Setelah dua artefak di atas tersedia, dilakukan kompilasi ulang untuk akurasi produksi.

Rencana Sprint Berikutnya

- Memperoleh scaler dan CNN extractor dari pemilik model, lalu kompilasi ulang HEF.
- Validasi akurasi pasca kuantisasi terhadap output pelatihan.
- Menambahkan auto-start container di Pi (systemd atau restart policy) untuk operasi lapangan.
- Mengaktifkan jalur preprocessing on-device (perhitungan NDVI dan ekstraksi fitur citra).

Tautan

- Repositori (kode, artefak, dokumentasi): <https://github.com/riyadh-gif/dini-deploy>
- Panduan serah terima tim hardware: docs/HANDOFF.md
- Status preprocessing dan langkah lanjut: docs/scaler_status.md